



Karar Ağaçları

YZL 401-Makine Öğrenmesi ve Yapay Zeka Dersi Sunumu



Karar Ağaçları

- Sınıflandırma problemleri için yaygın kullanılan yöntemdir.
- Sınıflandırma doğruluğu diğer öğrenme metotlarına göre çok etkindir.
- Öğrenmiş sınıflandırma modeli ağaç şeklinde gösterilir ve karar ağacı (decision tree) olarak adlandırılır.
- ID3 ve C4.5, entropiye dayalı sınıflandırma algoritmalarıdır.
- Twoing ve Gini, CART (Classification And Regression Trees) sınıflandırma ve regresyon ağaçlarına dayalı sınıflandırma algoritmalarıdır.
- CART algoritmalarında her düğümde bir kritere göre ikili bölünme yapılır.

Entropi

- Entropi, rastgele değere sahip bir değişken veya bir sistem için belirsizlik ölçütüdür.
- Enformasyon, rastsal bir olayın gerçekleşmesi halinde ortaya çıkan bilgi ölçütüdür.
- Bir süreç için entropi, tüm örnekler (durumlar) tarafından içerilen enformasyonun değeridir.
- Eşit olasılıklı durumlara sahip sistemler yüksek belirsizliğe sahiptirler.
- Shannon, bir sistemdeki durum değişikliğinde, entropideki değişimin enformasyon boyutunu tanımladığını öne sürmüştür.
- Buna göre bir sistemdeki belirsizlik arttıkça, bir durum gerçekleştiğinde elde edilecek enformasyon boyutu da artacaktır.

Entropi

- Shannon bilgiyi bitlerle ifade ettiği için, logaritmayı 2 tabanında kullanmıştır ve enformasyon formülünü aşağıdaki gibi vermiştir.

- $I(x) = \log_2 \frac{1}{P(x)} = -\log_2 P(x)$

- $P(x)$, x olayının gerçekleşme olasılığını gösterir.
- Shannon'a göre entropi, iletilen bir mesajın taşıdığı enformasyonun değeridir.
- Shannon entropisi H , aşağıdaki gibi ifade edilir:

- $H(x) = E(I(x)) = \sum_{i=1}^n P(x_i) \log_2 \frac{1}{P(x_i)} = -\sum_{i=1}^n P(x_i) \log_2 P(x_i)$

Entropi

5

- Bir paranın havaya atılması olayı rastsal X sürecini gösterebiliriz. Yazı ve tura gelme olasılıkları eşit olduğundan elde edilecek enformasyon,

- $I(x) = \log_2 \frac{1}{P(x)} = \log_2 \frac{1}{0,5} = \log_2 2 = 1$

olur. Bu olayın sonucunda 1 bitlik bilgi kazanılmıştır.

- Entropi değeri ise 1 olarak bulunur.

- $H(x) = E(I(x)) = - \sum_{i=1}^n P(x_i) \log_2 P(x_i) = (0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1$

ID3 Algoritması

- ID3(Iterative Dichotomiser 3)algoritması sadece kategorik verilerle çalışmaktadır.
- Karar ağaçları çok boyutlu veriyi belirlenmiş bir niteliğe göre parçalara böler.
- Her adımda verinin hangi özelliğine göre ne tür işlem yapılacağına karar verilir.
- Oluşturulabilecek tüm ağaçların kombinasyonu çok fazladır.
- Karar ağaçlarının en az düğüm ve yaprak ile oluşturulması için farklı algoritmalar kullanılarak bölme işlemi yapılır.

ID3 Algoritması

- Öncelikle sınıf niteliğinin entropisi hesaplanır.

- $$H(T) = - \sum_{i=1}^n P_i \log_2 P_i$$

- Sonra özellik vektörlerinin sınıfa bağımlı entropileri hesaplanır.

- $$H(X_k) = - \sum_{i=1}^n \frac{|T_i|}{|X_k|} \log_2 \frac{|T_i|}{|X_k|}$$

T_i: Çıkış sınıf vektörü değeri
X_k: Giriş özellik vektörü değeri
H(X,T): Sınıfa bağımlı entropi

- $$H(X, T) = \sum_{k=1}^n \frac{|X_k|}{|X|} H(X_k)$$

- Son olarak sınıf niteliğinin entropisinden tüm özellik vektörlerinin entropisi çıkartılarak her özellik için kazanç ölçütü hesaplanır. En büyük kazanca sahip özellik vektörü o iterasyon için dallanma düğümü olarak seçilir.

- $$Kazanç(X, T) = H(T) - H(X, T)$$

ID3 Algoritması

MÜŞTERİ	BORÇ	GELİR	STATÜ	RİSK
1	YÜKSEK	YÜKSEK	İŞVEREN	KÖTÜ
2	YÜKSEK	YÜKSEK	ÜCRETLİ	KÖTÜ
3	YÜKSEK	DÜŞÜK	ÜCRETLİ	KÖTÜ
4	DÜŞÜK	DÜŞÜK	ÜCRETLİ	İYİ
5	DÜŞÜK	DÜŞÜK	İŞVEREN	KÖTÜ
6	DÜŞÜK	YÜKSEK	İŞVEREN	İYİ
7	DÜŞÜK	YÜKSEK	ÜCRETLİ	İYİ
8	DÜŞÜK	DÜŞÜK	ÜCRETLİ	İYİ
9	DÜŞÜK	DÜŞÜK	İŞVEREN	KÖTÜ
10	DÜŞÜK	YÜKSEK	İŞVEREN	İYİ

$$H(STATU_{İŞVEREN}) = -\left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5}\right) = 0,971$$

$$H(STATU_{DÜŞÜK}) = -\left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5}\right) = 0,971 \quad = 1$$

$$\begin{aligned} H(STATU, RISK) &= \frac{5}{10} H(STATU_{YÜKSEK}) + \frac{5}{10} H(STATU_{DÜŞÜK}) \\ &= \frac{5}{10} (0,971) + \frac{5}{10} (0,971) = 0,971 \end{aligned}$$

$$Kazanç(STATU, RISK) = 1 - 0,971 = 0,029$$

İlk dallanma için uygun seçim BORÇ niteliğidir.

ID3 Algoritması

MÜŞTERİ	GELİR	STATÜ	RİSK
4	DÜŞÜK	ÜCRETLİ	İYİ
5	DÜŞÜK	İŞVEREN	KÖTÜ
6	YÜKSEK	İŞVEREN	İYİ
7	YÜKSEK	ÜCRETLİ	İYİ
8	DÜŞÜK	ÜCRETLİ	İYİ
9	DÜŞÜK	İŞVEREN	KÖTÜ
10	YÜKSEK	İŞVEREN	İYİ

$$H(S_{GELİR}) = -\left(\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4}\right) = 1$$

$$H(T) = -\left(\frac{2}{7} \log_2 \frac{2}{7} + \frac{5}{7} \log_2 \frac{5}{7}\right) = 0,86$$

$$H(S_{GELİR, RİSK}) = \frac{33}{77} \cdot 0 + \frac{44}{77} \cdot 1 = 0,57$$

$$Kazanç(S_{GELİR, RİSK}) = 0,86 - 0,57 = 0,29$$

ID3 Algoritması


10

1,2,3,4,5,6,7,8,9,10

RİSK

^{BOI} Karar ağacından elde edilen kurallar

1. **EĞER** (BORÇ = YÜKSEK) **İSE** (RİSK = KÖTÜ)
2. **EĞER** (BORÇ = DÜŞÜK) **VE** (GELİR = YÜKSEK) **İSE** (RİSK = İYİ)
3. **EĞER** (BORÇ = DÜŞÜK) **VE** (GELİR = DÜŞÜK) **VE** (STATÜ = ÜCRETLİ) **İSE** (RİSK = İYİ)
4. **EĞER** (BORÇ = DÜŞÜK) **VE** (GELİR = DÜŞÜK) **VE** (STATÜ = İŞVEREN) **İSE** (RİSK = KÖTÜ)



C4.5 Algoritması

11

- C4.5 ile sayısal değerlere sahip nitelikler için karar ağacı oluşturmak için Quinlan tarafından geliştirilmiştir.
- ID3 algoritmasından tek farkı nümerik değerlerin kategorik değerler haline dönüştürülmesidir.
- En büyük bilgi kazancını sağlayacak biçimde bir eşik değer belirlenir.
- Eşik değeri belirlemek için tüm değerler sıralanır ve ikiye bölünür.
- Eşik değer için $[v_i, v_{i+1}]$ aralığının orta noktası alınabilir.
 - $$t_i = \frac{v_i + v_{i+1}}{2}$$
- Nitelikteki değerler eşik değere göre iki kategoriye ayrılmış olur.

C4.5 Algoritması

NİTELİK1	NİTELİK2	NİTELİK3	SINIF
a	70	doğru	sınıf1
a	90	doğru	sınıf2
a	85	yanlış	sınıf2
a	95	yanlış	sınıf2
a	70	yanlış	sınıf1
b	90	doğru	sınıf1
b	78	yanlış	sınıf1
b	65	doğru	sınıf1
b	75	yanlış	sınıf1
c	80	doğru	sınıf2
c	70	doğru	sınıf2
c	80	yanlış	sınıf1
c	70	yanlış	sınıf1
c	96	yanlış	sınıf1

- Burada Nitelik2 sürekli verilerden oluşmaktadır.
- İlk aşamada verileri sıralıyoruz;
65,70,75,78,80,85,90,95,96
- $t_i = \frac{80+8}{2} \cong 83$ şeklinde eşik değeri belirlenir.

C4.5 Algoritması

NİTELİK1	NİTELİK2	NİTELİK3	SINIF
a	eşit veya küçük	doğru	sınıf1
a	büyük	doğru	sınıf2
a	büyük	yanlış	sınıf2
a	büyük	yanlış	sınıf2
a	eşit veya küçük	yanlış	sınıf1
b	büyük	doğru	sınıf1
b	eşit veya küçük	yanlış	sınıf1
b	eşit veya küçük	doğru	sınıf1
b	eşit veya küçük	yanlış	sınıf1
c	eşit veya küçük	doğru	sınıf2
c	eşit veya küçük	doğru	sınıf2
c	eşit veya küçük	yanlış	sınıf1
c	eşit veya küçük	yanlış	sınıf1
c	büyük	yanlış	sınıf1

- Burada Nitelik2 sürekli verilerden oluşmaktadır.
- İlk aşamada verileri sıralıyoruz; 65, 70, 75, 78, 80, 85, 90, 95, 96
- $t_i = \frac{80+85}{2} \cong 83$ şeklinde eşik değeri belirlenir.
- Daha sonra aynı ID3 Algoritması çözümü uygulanır.

*Dünya
Seni Bekliyor!*



Dinlediğiniz için teşekkürler!

Öğr. Gör. Mustafa Sami CÜCEN

Yazılım Mühendisliği



ostimteknik.edu.tr



Ostim, 100. Yıl Blv 55/F, Yenimahalle/Ankara



(0312) 386 10 92



/ostimteknikuniv

